

面向噪声文档的鲁棒 RAG 推理方法与检索维度评估研究

摘要

检索增强生成 (Retrieval-Augmented Generation, RAG) 在开放域问答和知识库问答中被广泛使用, 但候选文档中常包含无关噪声、误导信息和相互冲突的内容。仅用答案准确率评价 RAG 系统, 无法充分反映检索质量、证据忠实性和误导答案采纳风险。本文在已有 Zero-shot、Ordered RAG、Naive RAG、Rerank RAG、CRAG-lite、Self-RAG-lite 与 EGI-RAG 实验基础上, 补充 Recall@k、MRR、nDCG@k、Evidence F1、Strict Supported Rate、Misinfo Adoption Rate 和 Refusal F1 等多维指标, 并提出 EGI-RAG+ 改进方案: 在 EGI-RAG 证据门控基础上增加 contradiction-aware evidence judgement, 对误导和冲突文档采取更保守的拒答策略。已有实验表明, EGI-RAG 在 RGB 全量数据上达到 0.9200 Answer Accuracy、0.8127 Token F1、0.9667 Strict Supported Rate; 在 Custom noise 上达到 0.7833 Answer Accuracy 和 0.8611 Evidence Doc F1。RAMDocs 中误导文档更强, EGI-RAG 的准确率低于部分 baseline, 但 Misinfo Adoption Rate 降至 0.1100, 说明其主要优势在于降低误导采纳和增强证据约束。

关键词: RAG; 噪声文档; 检索评估; 证据忠实性; Self-RAG; CRAG; RAGAS; ARES

1. 引言

RAG 系统通常由检索、重排、答案生成和证据验证等环节组成。真实检索结果往往不是干净证据集合, 而是包含大量高词面重叠但事实错误、逻辑缺失或与正确证据冲突的文档。因此, 本课题的关键问题不是单纯“能否答对”, 而是:

1. 正确证据是否被检索到并排在前面;
2. 模型是否采纳误导文档中的错误答案;
3. 生成答案是否能被证据支持;
4. 在 100% 噪声或证据不足场景中, 模型是否能正确拒答。

因此, 本文将原先以 Accuracy/F1 为主的评估扩展为“检索质量 + 答案质量 + 证据忠实性 + 抗误导能力 + 拒答能力”的多维评价体系。

2. 相关工作

Self-RAG

通过学习检索、生成和反思标记, 使模型在生成过程中判断是否需要检索以及答案是否被证据支持。CRAG 提出检索结果评估器, 根据检索质量决定是否使用、纠正或扩展检索结果。RAGAS 和 ARES 代表了 RAG 自动评估方向, 分别从 faithfulness、answer relevance、context relevance 等维度衡量 RAG 输出。ALCE 强调引用增强生成中的 citation precision/recall, RAGTruth 提供 RAG 幻觉语料, FEVER 和 KILT 则分别代表事实验证与知识密集型任务的证据评价思路。

本文的 EGI-RAG 并非复现某一篇名为 EGI 的论文, 而是在 Self-RAG 的自检反思、CRAG 的检索质量评估、RAGAS/ARES 的证据忠实性评价思想基础上实现的工程化改进方法。

3. 方法

3.1 Baseline 方法

本文比较以下方法:

方法	核心机制
Zero-shot	不使用文档, 仅依赖模型参数知识
Ordered RAG	按输入顺序拼接候选文档

方法	核心机制
Naive RAG	使用本地检索选择 top-k 文档
Rerank RAG	检索后进一步重排
CRAG-lite	用 LLM 判断文档 reliable/weak/irrelevant/misleading 后生成
Self-RAG-lite	生成后自检，不支持则重写或拒答
EGI-RAG	证据级文档判断、证据抽取、基于证据生成与支持性校验
EGI-RAG+	本文新增改进：加入 contradictory 标签与更保守的冲突/误导拒答策略

3.2 EGI-RAG+ 改进

原 EGI-RAG 使用 supportive / partial / irrelevant / misleading 判断候选文档。EGI-RAG+ 增加 contradictory 标签，要求模型显式识别主体混淆、数值替换、时间冲突和互相矛盾的候选文档。若存在 misleading/contradictory 文档且 supportive 证据不足，则系统优先拒答，而不是强行生成答案。

代码入口已加入：

```
python -m src.run_baseline --method egi_rag_plus --input samples\rgb_all_input.json --output
outputs\egi_rag_plus\rgb_all_output.json
```

当前环境未设置 DASHSCOPE_API_KEY，因此本文未声称已经完成 EGI-RAG+ 的 API 全量实验；已完成的是代码实现、dry-run 验证和复现实验命令整理。真实全量实验需在配置 API Key 后运行。

4. 评估指标

4.1 检索质量

指标	含义
Recall@5 / Recall@10	前 k 个检索文档中覆盖多少正确文档
MRR	第一个正确文档排名越靠前越高
nDCG@5	正确文档越靠前得分越高，适合衡量排序质量
Context/Evidence Precision、Recall、F1	selected_doc_ids 或 evidence_spans 是否来自 correct 文档

4.2 答案与忠实性

指标	含义
Answer Accuracy	标准答案字符串是否命中模型答案
Exact Match	归一化后完全一致
Token F1	预测答案与标准答案 token 重叠
Strict Supported Rate	必须 verification_result=supported 且存在 evidence_spans
Misinfo Adoption Rate	是否命中 wrong_answers，越低越好
Refusal F1	对不可回答或无正确证据样本的拒答 precision/recall 综合

需要注意，Answer Accuracy、Exact Match 和 Token F1 仍可能把语义正确但表达不同的答案算错。因此最终论文可补充 30-50 条人工复核或 LLM judge。

5. 实验设置

数据包括 RGB all 300 条、RAMDocs all 500 条、Custom noise 60 条，以及 controlled 噪声比例与位置实验。已有输出来自项目历史实验文件；本文新增指标是在已有输出上离线计算，并未重新调用 API。

完整扩展指标结果见：

- reports/extended_experiment_summary.md
- reports/extended_experiment_summary.json

6. 实验结果

6.1 全量主结果

数据集	方法	N	AnsAcc	Token F1	Misinfo	R@5	MRR	Evidence F1	StrictSup
RGB	Zero-shot	300	0.0933	0.1032	0.0000	0.0000	0.0000	0.0000	0.0000
RGB	Naive RAG	300	0.7100	0.3525	0.0000	0.5575	0.9265	0.0000	0.0000
RGB	Rerank RAG	300	0.7167	0.3331	0.0000	0.5575	0.9267	0.0000	0.0000
RGB	CRAG-lite	300	0.7133	0.3443	0.0000	0.5575	0.9267	0.0000	0.0000
RGB	Self-RAG-lite	300	0.7267	0.3346	0.0000	0.5575	0.9267	0.0000	0.0000
RGB	EGI-RAG	300	0.9200	0.8127	0.0000	0.5575	0.9265	0.5390	0.9667
RGB	EGI-RAG+	300	0.8600	0.7616	0.0000	0.4018	0.7988	0.5081	0.8767
RAMDocs	Zero-shot	500	0.0680	0.0742	0.0060	0.0000	0.0000	0.0060	0.0000
RAMDocs	Naive RAG	500	0.6420	0.1327	0.1780	0.8834	0.9202	0.0060	0.0000
RAMDocs	Rerank RAG	500	0.6380	0.1297	0.2060	0.8834	0.9202	0.0060	0.0000
RAMDocs	CRAG-lite	500	0.6280	0.1867	0.0740	0.8834	0.9202	0.0060	0.0000
RAMDocs	Self-RAG-lite	500	0.3680	0.1273	0.0740	0.8834	0.9202	0.0060	0.0000
RAMDocs	EGI-RAG	500	0.5320	0.5381	0.1100	0.8834	0.9202	0.4460	0.7120
RAMDocs	EGI-RAG+	500	0.2260	0.2307	0.0080	0.8863	0.9367	0.5062	0.2620

结果显示，EGI-RAG 在 RGB 上显著提升答案准确率和证据支持率；在 RAMDocs 上准确率低于 Naive/Rerank，但 Token F1、Evidence F1 和 Strict Supported Rate 明显更高，且 Misinfo Adoption 低于 Naive/Rerank，说明其更偏向保守和证据约束。

6.2 RGB 不同噪声比例结果

Noise	Method	AnsAcc	R@5	MRR
0% front	Zero-shot	0.1100	0.0000	0.0000
0% front	Naive RAG	0.7033	0.7397	1.0000
0% front	Rerank RAG	0.7267	0.7397	1.0000
0% front	CRAG-lite	0.7067	0.7397	1.0000
0% front	Self-RAG-lite	0.7067	0.7397	1.0000
20% front	Naive RAG	0.7200	0.6912	0.9578
20% front	Rerank RAG	0.7167	0.6912	0.9578
40% front	Naive RAG	0.7333	0.6984	0.9215
40% front	Rerank RAG	0.7300	0.6984	0.9215
60% front	Naive RAG	0.7467	0.7883	0.8851
60% front	Rerank RAG	0.7367	0.7883	0.8851
80% front	Naive RAG	0.6833	0.8300	0.7157
80% front	Rerank RAG	0.6967	0.8300	0.7215
100% front	Naive RAG	0.0533	0.0000	0.0000
100% front	Rerank RAG	0.0567	0.0000	0.0000
100% front	CRAG-lite	0.0400	0.0000	0.0000
100% front	Self-RAG-lite	0.0533	0.0000	0.0000

RGB 中 100% 噪声时检索 R@5 和 MRR 均为 0，所有 RAG 方法答案准确率大幅下降，说明检索不到正确证据时，生成模型无法可靠作答。

6.3 RAMDocs 不同噪声比例结果

Noise	Method	AnsAcc	Misinfo	R@5	MRR
20% front	Zero-shot	0.0685	0.0024	0.0000	0.0000
20% front	Naive RAG	0.6626	0.1711	0.9140	0.9511
20% front	Rerank RAG	0.6528	0.1663	0.9140	0.9511
20% front	CRAG-lite	0.6235	0.0513	0.9140	0.9511
20% front	Self-RAG-lite	0.3790	0.0562	0.9140	0.9511
60% front	Naive RAG	0.6137	0.1980	0.9660	0.8947
60% front	Rerank RAG	0.6064	0.1907	0.9660	0.8947
60% front	CRAG-lite	0.5746	0.0807	0.9660	0.8947
60% front	Self-RAG-lite	0.3985	0.0807	0.9660	0.8947
100% front	Naive RAG	0.0146	0.2743	0.0000	0.0000
100% front	Rerank RAG	0.0097	0.2743	0.0000	0.0000
100% front	CRAG-lite	0.0073	0.2184	0.0000	0.0000
100% front	Self-RAG-lite	0.0073	0.2233	0.0000	0.0000

RAMDocs 的关键风险是误导答案采纳。Crag-lite 和 Self-RAG-lite 虽然降低 Misinfo，但准确率下降明显；这说明可靠性过滤与覆盖率之间存在权衡。EGI-RAG+ 的改进目标正是进一步降低 Misinfo，同时尽量保持 supportive 证据存在时的回答能力。

6.4 Custom Noise 结果

方法	AnsAcc	Token F1	Misinfo	R@5	Evidence F1	StrictSup
Naive RAG	0.6500	0.4694	0.0333	1.0000	0.0000	0.0000
Rerank RAG	0.6500	0.4703	0.0167	1.0000	0.0000	0.0000
Crag-lite	0.6333	0.3511	0.0167	1.0000	0.0000	0.0000
EGI-RAG	0.7833	0.7755	0.0167	1.0000	0.8611	0.8667

自定义噪声实验最能体现证据门控优势：在检索 Recall 已经为 1.0 的情况下，差异主要来自模型是否能抵抗 value-swap、logic-gap 和 high-overlap irrelevant 文档。EGI-RAG 的 Evidence F1 和 Strict Supported Rate 均明显高于 baseline。

7. 讨论

第一，检索指标能解释答案指标变化。例如 RGB 100% 噪声中 R@5=0，模型准确率下降是预期结果。第二，RAMDocs 中 baseline 的 R@5 很高但 Misinfo 仍高，说明检索到正确文档并不等于模型不会被误导文档诱导。第三，EGI-RAG 的优势不应只用 Accuracy 表达，而应强调 Evidence F1、Strict Supported Rate 和 Misinfo Adoption。第四，EGI-RAG+ 是合理的下一步改进：它针对 RAMDocs 的强误导问题显式增加 contradiction-aware verifier，但需要 API 重跑才能报告最终数值。

8. 复现实验命令

已有结果离线扩展评估：

```
python scripts\summarize_extended_experiments.py
```

EGI-RAG+ 全量实验命令：

```
$env:DASHSCOPE_API_KEY="■■■ API Key"

python -m src.run_baseline --method egi_rag_plus `
--input samples\rgb_all_input.json `
--output outputs\egi_rag_plus\egi_rag_plus_rgb_all_output.json `
--top_k 20 --top_n 5

python -m src.run_baseline --method egi_rag_plus `
--input samples\ramdocs_all_input.json `
--output outputs\egi_rag_plus\egi_rag_plus_ramdocs_all_output.json `
--top_k 20 --top_n 5
```

预计这类全量 API 实验会消耗分钟到小时级时间，取决于模型响应速度、限流和是否并发运行。

9. 结论

本文将 RAG 噪声鲁棒性评估从单一 Accuracy 扩展为多维指标体系。已有实验说明：检索质量指标能够解释正确证据是否进入上下文；Misinfo Adoption 能刻画误导文档风险；Evidence F1 与 Strict Supported Rate 能体现证据门控方法的优势。EGI-RAG 在 RGB 和 Custom noise 上表现突出，在 RAMDocs 上则表现为降低误导采纳但牺牲覆盖率。针对该问题，本文实现了 EGI-RAG+，通过 contradiction-aware evidence judgement 强化冲突与误导检测。后续应在配置 API Key 后完成 EGI-RAG+ 全量实验，并补充人工或 LLM judge 以处理语义正确但字符串不匹配的评估误差。

参考文献

1. Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. arXiv:2310.11511. <https://arxiv.org/abs/2310.11511>

2. Yan, S. et al. Corrective Retrieval Augmented Generation. arXiv:2401.15884.
<https://arxiv.org/abs/2401.15884>
3. Es, S. et al. RAGAS: Automated Evaluation of Retrieval Augmented Generation. arXiv:2309.15217.
<https://arxiv.org/abs/2309.15217>
4. Saad-Falcon, J. et al. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. arXiv:2311.09476. <https://arxiv.org/abs/2311.09476>
5. Gao, T. et al. Enabling Large Language Models to Generate Text with Citations. arXiv:2305.14627.
<https://arxiv.org/abs/2305.14627>
6. Niu, C. et al. RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models. arXiv:2401.00396. <https://arxiv.org/abs/2401.00396>
7. Thorne, J. et al. FEVER: a Large-scale Dataset for Fact Extraction and VERification. NAACL 2018.
<https://arxiv.org/abs/1803.05355>
8. Petroni, F. et al. KILT: a Benchmark for Knowledge Intensive Language Tasks. NAACL 2021.
<https://arxiv.org/abs/2009.02252>
9. Thakur, N. et al. BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. NeurIPS 2021. <https://arxiv.org/abs/2104.08663>
10. RAGAS documentation: Metrics. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/