

面向噪声文档的鲁棒 RAG 推理方法与检索维度评估研究

摘要

检索增强生成 (Retrieval-Augmented Generation, RAG) 在开放域问答和知识库问答中被广泛使用, 但候选文档中常包含无关噪声、误导信息和相互冲突的内容。仅用答案准确率评价 RAG 系统, 无法充分反映检索质量、证据忠实性和误导答案采纳风险。本文在已有 Zero-shot、Ordered RAG、Naive RAG、Rerank RAG、CRAG-lite、Self-RAG-lite 与 EGI-RAG 实验基础上, 补充 Recall@k、MRR、nDCG@k、Evidence F1、Strict Supported Rate、Misinfo Adoption Rate 和 Refusal F1 等多维指标, 并提出 EGI-RAG+ 改进方案: 在 EGI-RAG 证据门控基础上增加 contradiction-aware evidence judgement, 对误导和冲突文档采取更保守的拒答策略。全量实验表明, EGI-RAG 在 RGB 上达到 0.9200 Answer Accuracy、0.8127 Token F1、0.9667 Strict Supported Rate; EGI-RAG+ 在 RAMDocs 上将 Misinfo Adoption Rate 从 EGI-RAG 的 0.1100 降至 0.0080, 但 Answer Accuracy 从 0.5320 下降到 0.2260, 说明强冲突门控能显著抑制误导采纳, 但也会造成过度拒答和覆盖率损失。

关键词: RAG; 噪声文档; 检索评估; 证据忠实性; Self-RAG; CRAG; RAGAS; ARES

1. 引言

RAG 系统通常由检索、重排、答案生成和证据验证等环节组成。真实检索结果往往不是干净证据集合, 而是包含大量高词面重叠但事实错误、逻辑缺失或与正确证据冲突的文档。因此, 本课题的关键问题不是单纯“能否答对”, 而是:

1. 正确证据是否被检索到并排在前面;
2. 模型是否采纳误导文档中的错误答案;
3. 生成答案是否能被证据支持;
4. 在 100% 噪声或证据不足场景中, 模型是否能正确拒答。

因此, 本文将原先以 Accuracy/F1 为主的评估扩展为“检索质量 + 答案质量 + 证据忠实性 + 抗误导能力 + 拒答能力”的多维评价体系。

2. 相关工作

Self-RAG 通过学习检索、生成和反思标记, 使模型在生成过程中判断是否需要检索以及答案是否被证据支持。CRAG 提出检索结果评估器, 根据检索质量决定是否使用、纠正或扩展检索结果。RAGAS 和 ARES 代表了 RAG 自动评估方向, 分别从 faithfulness、answer relevance、context relevance 等维度衡量 RAG 输出。ALCE 强调引用增强生成中的 citation precision/recall, RAGTruth 提供 RAG 幻觉语料, FEVER 和 KILT 则分别代表事实验证与知识密集型任务的证据评价思路。

本文的 EGI-RAG 并非复现某一篇名为 EGI 的论文, 而是在 Self-RAG 的自检反思、CRAG 的检索质量评估、RAGAS/ARES 的证据忠实性评价思想基础上实现的工程化改进方法。

3. 方法

3.1 Baseline 方法

本文比较以下方法：

方法	核心机制
Zero-shot	不使用文档，仅依赖模型参数知识
Ordered RAG	按输入顺序拼接候选文档
Naive RAG	使用本地检索选择 top-k 文档
Rerank RAG	检索后进一步重排
CRAG-lite	用 LLM 判断文档 reliable/weak/irrelevant/misleading 后生成
Self-RAG-lite	生成后自检，不支持则重写或拒答
EGI-RAG	证据级文档判断、证据抽取、基于证据生成与支持性校验
EGI-RAG+	本文新增改进：加入 contradictory 标签与更保守的冲突/误导拒答策略

3.2 EGI-RAG+ 改进

原 EGI-RAG 使用 supportive / partial / irrelevant / misleading 判断候选文档。EGI-RAG+ 增加 contradictory 标签，要求模型显式识别主体混淆、数值替换、时间冲突和互相矛盾的候选文档。若存在 misleading/contradictory 文档且 supportive 证据不足，则系统优先拒答，而不是强行生成答案。

代码入口已加入：

```
python -m src.run_baseline --method egi_rag_plus --input samples\rgb_all_input.json --output outputs\egi_rag_plus\rgb_all_output.json
```

EGI-RAG+ 已完成 RGB 300 条和 RAMDocs 500 条全量 API 实验，输出位于 outputs/egi_rag_plus/。实验使用百炼 DashScope/Qwen 兼容 Chat Completions API，并发运行 RGB 与 RAMDocs，每个任务 4 worker；RAMDocs 中 1 条网络断连样本已通过 --resume 多线程补跑成功。

4. 评估指标

4.1 检索质量

指标	含义
Recall@5 / Recall@10	前 k 个检索文档中覆盖多少正确文档
MRR	第一个正确文档排名越靠前越高

指标	含义
nDCG@5	正确文档越靠前得分越高，适合衡量排序质量
Context/Evidence Precision、Recall、F1	selected_doc_ids 或 evidence_spans 是否来自 correct 文档

4.2 答案与忠实性

指标	含义
Answer Accuracy	标准答案字符串是否命中模型答案
Exact Match	归一化后完全一致
Token F1	预测答案与标准答案 token 重叠
Strict Supported Rate	必须 verification_result=supported 且存在 evidence_spans
Misinfo Adoption Rate	是否命中 wrong_answers，越低越好
Refusal F1	对不可回答或无正确证据样本的拒答 precision/recall 综合

需要注意，Answer Accuracy、Exact Match 和 Token F1 仍可能把语义正确但表达不同的答案算错。因此最终论文可补充 30-50 条人工复核或 LLM judge。

5. 实验设置

数据包括 RGB all 300 条、RAMDocs all 500 条、Custom noise 60 条，以及 controlled 噪声比例与位置实验。baseline 与 EGI-RAG 使用项目历史输出文件；EGI-RAG+ 为本次新增全量 API 实验。所有指标均通过统一扩展评估脚本计算。

完整扩展指标结果见：

- reports/extended_experiment_summary.md
- reports/extended_experiment_summary.json

6. 实验结果

6.1 全量主结果

为避免误解，本文将全量结果拆成两张表。表 1 报告所有方法都具备的通用指标，包括答案质量、误导采纳、检索排序和 selected context 质量。表 2 只报告具备显式 evidence_spans 与 verification_result 的 EGI 系列方法；普通 baseline 不输出证据链，因此不参与 Evidence F1 和 Strict Supported Rate 的横向比较。

表 1：通用答案与检索指标

数据集	方法	N	AnsAcc	Token F1	Misinfo	R@5	MRR	nDCG@5	SelectedCtx F1
RGB	Zero-shot	300	0.0933	0.1032	0.0000	0.0000	0.0000	0.0000	0.0000
RGB	Naive RAG	300	0.7100	0.3525	0.0000	0.5575	0.9265	0.8332	0.6395
RGB	Rerank RAG	300	0.7167	0.3331	0.0000	0.5575	0.9267	0.8332	0.7276
RGB	CRAG-lite	300	0.7133	0.3443	0.0000	0.5575	0.9267	0.8332	0.7319
RGB	Self-RAG-lite	300	0.7267	0.3346	0.0000	0.5575	0.9267	0.8332	0.7276
RGB	EGI-RAG	300	0.9200	0.8127	0.0000	0.5575	0.9265	0.8332	0.5363
RGB	EGI-RAG+	300	0.8600	0.7616	0.0000	0.4018	0.7988	0.6263	0.5081
RAMDocs	Zero-shot	500	0.0680	0.0742	0.0060	0.0000	0.0000	0.0000	0.0000
RAMDocs	Naive RAG	500	0.6420	0.1327	0.1780	0.8834	0.9202	0.8933	0.7654
RAMDocs	Rerank RAG	500	0.6380	0.1297	0.2060	0.8834	0.9202	0.8933	0.7729
RAMDocs	CRAG-lite	500	0.6280	0.1867	0.0740	0.8834	0.9202	0.8933	0.6813
RAMDocs	Self-RAG-lite	500	0.3680	0.1273	0.0740	0.8834	0.9202	0.8933	0.7729
RAMDocs	EGI-RAG	500	0.5320	0.5381	0.1100	0.8834	0.9202	0.8933	0.4460
RAMDocs	EGI-RAG+	500	0.2260	0.2307	0.0080	0.8863	0.9367	0.8995	0.5062

表 2: EGI 系列证据链与验证指标

数据集	方法	Evidence F1	Evidence Rate	Strict Supported	解释
RGB	EGI-RAG	0.5390	1.0000	0.9667	答案准确率和支持性最高
RGB	EGI-RAG+	0.5081	0.9800	0.8767	更保守，准确率略降
RAMDocs	EGI-RAG	0.4460	0.8920	0.7120	在误导文档中保持一定覆盖率
RAMDocs	EGI-RAG+	0.5062	0.9460	0.2620	误导采纳率最低，但 verifier 更保守

结果显示，EGI-RAG 在 RGB 上显著提升答案准确率和证据支持率；在 RAMDocs 上准确率低于 Naive/Rerank，但 Token F1、Evidence F1 和 Strict Supported Rate 明显更高，且 Misinfo Adoption 低于 Naive/Rerank，说明其更偏向保守和证据约束。EGI-RAG+ 进一步降低 RAMDocs 的误导采纳率至 0.0080，并提升 Evidence F1 至 0.5062，但准确率和 Strict Supported Rate 下降，说明当前 contradiction-aware 策略过于保守，后续需要调节“遇到冲突即拒答”的阈值。

6.2 RGB 不同噪声比例结果

Noise	Method	AnsAcc	R@5	MRR
0% front	Zero-shot	0.1100	0.0000	0.0000
0% front	Naive RAG	0.7033	0.7397	1.0000

Noise	Method	AnsAcc	R@5	MRR
0% front	Rerank RAG	0.7267	0.7397	1.0000
0% front	CRAG-lite	0.7067	0.7397	1.0000
0% front	Self-RAG-lite	0.7067	0.7397	1.0000
20% front	Naive RAG	0.7200	0.6912	0.9578
20% front	Rerank RAG	0.7167	0.6912	0.9578
40% front	Naive RAG	0.7333	0.6984	0.9215
40% front	Rerank RAG	0.7300	0.6984	0.9215
60% front	Naive RAG	0.7467	0.7883	0.8851
60% front	Rerank RAG	0.7367	0.7883	0.8851
80% front	Naive RAG	0.6833	0.8300	0.7157
80% front	Rerank RAG	0.6967	0.8300	0.7215
100% front	Naive RAG	0.0533	0.0000	0.0000
100% front	Rerank RAG	0.0567	0.0000	0.0000
100% front	CRAG-lite	0.0400	0.0000	0.0000
100% front	Self-RAG-lite	0.0533	0.0000	0.0000

RGB 中 100% 噪声时检索 R@5 和 MRR 均为 0，所有 RAG 方法答案准确率大幅下降，说明检索不到正确证据时，生成模型无法可靠作答。

6.3 RAMDocs 不同噪声比例结果

Noise	Method	AnsAcc	Misinfo	R@5	MRR
20% front	Zero-shot	0.0685	0.0024	0.0000	0.0000
20% front	Naive RAG	0.6626	0.1711	0.9140	0.9511
20% front	Rerank RAG	0.6528	0.1663	0.9140	0.9511
20% front	CRAG-lite	0.6235	0.0513	0.9140	0.9511
20% front	Self-RAG-lite	0.3790	0.0562	0.9140	0.9511
60% front	Naive RAG	0.6137	0.1980	0.9660	0.8947
60% front	Rerank RAG	0.6064	0.1907	0.9660	0.8947
60% front	CRAG-lite	0.5746	0.0807	0.9660	0.8947
60% front	Self-RAG-lite	0.3985	0.0807	0.9660	0.8947
100% front	Naive RAG	0.0146	0.2743	0.0000	0.0000
100% front	Rerank RAG	0.0097	0.2743	0.0000	0.0000
100% front	CRAG-lite	0.0073	0.2184	0.0000	0.0000

Noise	Method	AnsAcc	Misinfo	R@5	MRR
100% front	Self-RAG-lite	0.0073	0.2233	0.0000	0.0000

RAMDocs 的关键风险是误导答案采纳。CRAG-lite 和 Self-RAG-lite 虽然降低 Misinfo，但准确率下降明显；这说明可靠性过滤与覆盖率之间存在权衡。EGI-RAG+ 的改进目标正是进一步降低 Misinfo，同时尽量保持 supportive 证据存在时的回答能力。

6.4 Custom Noise 结果

方法	AnsAcc	Token F1	Misinfo	R@5	Evidence F1	StrictSup
Naive RAG	0.6500	0.4694	0.0333	1.0000	0.0000	0.0000
Rerank RAG	0.6500	0.4703	0.0167	1.0000	0.0000	0.0000
CRAG-lite	0.6333	0.3511	0.0167	1.0000	0.0000	0.0000
EGI-RAG	0.7833	0.7755	0.0167	1.0000	0.8611	0.8667

自定义噪声实验最能体现证据门控优势：在检索 Recall 已经为 1.0 的情况下，差异主要来自模型是否能抵抗 value-swap、logic-gap 和 high-overlap irrelevant 文档。EGI-RAG 的 Evidence F1 和 Strict Supported Rate 均明显高于 baseline。

7. 讨论

第一，检索指标能解释答案指标变化。例如 RGB 100% 噪声中 R@5=0，模型准确率下降是预期结果。第二，RAMDocs 中 baseline 的 R@5 很高但 Misinfo 仍高，说明检索到正确文档并不等于模型不会被误导文档诱导。第三，EGI-RAG 的优势不应只用 Accuracy 表达，而应强调 Evidence F1、Strict Supported Rate 和 Misinfo Adoption。第四，EGI-RAG+ 证明 contradiction-aware verifier 能显著降低误导采纳，但当前版本过度保守：RAMDocs Misinfo 从 0.1100 降到 0.0080 的同时，Answer Accuracy 从 0.5320 降到 0.2260。因此更合理的后续版本应采用软阈值策略，例如只有当冲突文档数量超过 supportive 证据数量，或 verifier 明确判定 conflict 时才拒答。

8. 复现实验命令

已有结果离线扩展评估：

```
python scripts\summarize_extended_experiments.py
```

EGI-RAG+ 全量实验命令：

```
$env:DASHSCOPE_API_KEY="你的 API Key"
```

```
python -m src.run_baseline --method egi_rag_plus `
  --input samples\rgb_all_input.json `
  --output outputs\egi_rag_plus\egi_rag_plus_rgb_all_output.json `
```

```
--top_k 20 --top_n 5

python -m src.run_baseline --method egi_rag_plus `
--input samples\ramdocs_all_input.json `
--output outputs\egi_rag_plus\egi_rag_plus_ramdocs_all_output.json `
--top_k 20 --top_n 5`
```

预计这类全量 API 实验会消耗分钟到小时级时间，取决于模型响应速度、限流和是否并发运行。

9. 结论

本文将 RAG 噪声鲁棒性评估从单一 Accuracy 扩展为多维指标体系。已有实验说明：检索质量指标能够解释正确证据是否进入上下文；Misinfo Adoption 能刻画误导文档风险；Evidence F1 与 Strict Supported Rate 能体现证据门控方法的优势。EGI-RAG 在 RGB 和 Custom noise 上表现突出，在 RAMDocs 上则表现为降低误导采纳但牺牲覆盖率。本文实现并全量测试了 EGI-RAG+，通过 contradiction-aware evidence judgement 将 RAMDocs Misinfo Adoption Rate 降至 0.0080，但也暴露出过度拒答问题。后续应引入软冲突阈值、LLM judge 或人工复核，以处理语义正确但字符串不匹配的评估误差，并在降低误导采纳的同时恢复可回答样本覆盖率。

参考文献

1. Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. arXiv:2310.11511. <https://arxiv.org/abs/2310.11511>
2. Yan, S. et al. Corrective Retrieval Augmented Generation. arXiv:2401.15884. <https://arxiv.org/abs/2401.15884>
3. Es, S. et al. RAGAS: Automated Evaluation of Retrieval Augmented Generation. arXiv:2309.15217. <https://arxiv.org/abs/2309.15217>
4. Saad-Falcon, J. et al. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. arXiv:2311.09476. <https://arxiv.org/abs/2311.09476>
5. Gao, T. et al. Enabling Large Language Models to Generate Text with Citations. arXiv:2305.14627. <https://arxiv.org/abs/2305.14627>
6. Niu, C. et al. RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models. arXiv:2401.00396. <https://arxiv.org/abs/2401.00396>
7. Thorne, J. et al. FEVER: a Large-scale Dataset for Fact Extraction and VERification. NAACL 2018. <https://arxiv.org/abs/1803.05355>
8. Petroni, F. et al. KILT: a Benchmark for Knowledge Intensive Language Tasks. NAACL 2021. <https://arxiv.org/abs/2009.02252>
9. Thakur, N. et al. BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. NeurIPS 2021. <https://arxiv.org/abs/2104.08663>
10. RAGAS documentation: Metrics. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/