

面向噪声文档的鲁棒 RAG 推理方法与检索维度评估

自然语言处理课程项目

Abstract

检索增强生成系统在开放域问答中经常面对无关文档、误导文档和冲突文档。仅用答案准确率评价 RAG 系统，无法揭示正确证据是否被检索、模型是否采纳错误答案，以及答案是否真正被证据支持。本文围绕 RGB、RAMDocs、controlled noise 和 custom noise 数据，比较 Zero-shot、Ordered RAG、Naive RAG、Rerank RAG、CRAG-lite、Self-RAG-lite、EGI-RAG 与 EGI-RAG+。我们将评估扩展为 Recall@k、MRR、nDCG、Evidence F1、Strict Supported Rate、Misinfo Adoption Rate 和 Refusal F1。结果显示，EGI-RAG 在 RGB 和自定义噪声上具有较强证据约束能力；EGI-RAG+ 可显著降低 RAMDocs 的误导答案采纳，但因过度拒答导致 Answer Accuracy 下降。

Keywords: Retrieval-Augmented Generation; Noisy Documents; Evidence Gating; Misinformation Adoption; Refusal.

1 Introduction

真实 RAG 候选文档并不总是干净证据集合。候选集中可能同时包含正确证据、普通噪声、高重叠误导文档和互相冲突的信息。RAG 的目标不是让模型读取更多文档，而是让模型只基于可信证据作答，并在证据不足或冲突时拒答。本文的核心问题包括：正确证据是否进入 top-k；模型是否被 wrong answer spans 文档诱导；生成答案是否有 evidence spans 支持；100% 噪声场景中系统能否拒答。

2 System Overview

图 1 展示项目总流程。成员 A 负责 RGB、RAMDocs 与 Conflicts 数据转换和 controlled noise 构造；成员 B 负责 Qwen/百炼 API、baseline、检索重排和基础评估；成员 C 负责 EGI-RAG、EGI-RAG+、扩展指标和最终分析。

3 Method

EGI-RAG 首先对候选文档进行本地检索和重排，再用 LLM 判断每篇文档是否为 supportive、partial、irrelevant 或 misleading。系统只从 supportive 文档中抽取最短原文证据句，并只将 evidence spans 输入答案生成器。答案生成后，verifier 判断其是否 supported。若 verification result 为 unsupported、conflict 或 insufficient，则系统拒答。

Dataset	Method	N	Acc	Misinfo	Strict
RGB	EGI	300	0.9200	0.0000	0.9667
RGB	EGI+	300	0.8600	0.0000	0.8767
RAM	EGI	500	0.5320	0.1100	0.7120
RAM	EGI+	500	0.2260	0.0080	0.2620

Table 1: EGI-RAG 与 EGI-RAG+ 全量结果。EGI-RAG+ 降低 Misinfo，但 Answer Accuracy 与 Strict Supported Rate 下降。

EGI-RAG+ 在 EGI-RAG 的基础上加入 contradictory 标签，试图识别主体混淆、数值替换、时间冲突和互相矛盾文档。其 misinformation adoption，而不是直接提高 Answer Accuracy。当前实现采用 hard gate，因此在降低误导采纳的同时也带来过度拒答。

4 Evaluation

除 Answer Accuracy 和 Token F1 外，本文重点使用检索指标 Recall@10、MRR、nDCG@5，以及证据与鲁棒性指标 Evidence F1、Strict Supported Rate、Misinfo Adoption Rate 和 Refusal F1。Misinfo Adoption Rate 越低越好，它衡量模型是否命中 RAMDocs wrong answers。

5 Main Results

表 1 显示，EGI-RAG 在 RGB 上达到 0.9200 Answer Accuracy 和 0.9667 Strict Supported Rate。RAMDocs 中 EGI-RAG+ 将 Misinfo Adoption 从 0.1100 降到 0.0080，但 Answer Accuracy 从 0.5320 降到 0.2260。这说明 EGI-RAG+ 更像风险控制策略，而不是准确率增强策略。

6 Controlled Noise Results

RGB 中 0% 和 60% 普通噪声下，EGI-RAG 仍保持较高准确率。100% 噪声时 Recall@5 和 MRR 为 0，模型没有正确证据，因此 Accuracy 大幅下降。RAMDocs 的关键风险是 high-overlap misinfo：即使检索命中正确文档，模型仍可能被 wrong answer 诱导。

面向噪声文档的 RAG 鲁棒性推理实验流程与成员分工




Figure 1: RAG 鲁棒性实验全流程与成员分工。流程覆盖数据转换、controlled/custom noise 构造、baseline 运行、EGI-RAG 实现和扩展指标评估。

Setting	Method	N	Acc	Strict
RGB 0%	EGI	300	0.9600	0.9967
RGB 60%	EGI	300	0.9300	0.9667
RGB 100%	EGI	300	0.0400	0.1233
RAM 60%	EGI	118	0.5424	0.7288
RAM 60%	EGI+	100	0.3100	0.3500
RAM 100%	EGI+	100	0.0000	0.2900

Table 2: Controlled noise 代表性比例。RGB 全噪声下正确证据缺失；RAMDocs 中误导文档更危险。

7 Custom Noise

自定义噪声包含 logic-gap、value-swap 和 high-overlap irrelevant 三类场景。EGI-RAG 在该集合上达到 0.7833 Accuracy、0.7755 Token F1、0.8611 Evidence F1 和 0.8667 Strict Supported Rate, 明显优于 Naive/Rerank/CRAG-lite。该结果说明证据门控特别适合处理“看似相关但缺少关键逻辑”的文档。

8 Failure Analysis

错误主要来自五类原因。第一，检索不到正确证据，尤其是 100% noise；第二，正确证据与强误导文档共现，RAMDocs 中很常见；第三，证据抽取不完整，例如抽到主体但遗漏时间或数值；第四，EGI-Automated Evaluation of Retrieval RAG+ 过度拒答；第五，字符串评估误差，例如日期格式和别名导致语义正确答案被判错。

9 Discussion

EGI-RAG+ 看起来“效果变差”的根本原因是目标函数改变。它优先 misinformation adoption, 而不是最大化 Answer Accuracy。未来应将 hard gate 改为 soft threshold: 只有当 contradictory 文档数量或冲突强度超过 supportive evidence 时拒答；同时引入 LLM judge 或人工复核，减少字符串指标误差。

10 Conclusion

本文将噪声文档下的 RAG 评价从单一答案准确率扩展为检索、证据和鲁棒性多维指标。EGI-RAG 能在 RGB 和 custom noise 上提升证据忠实性；EGI-RAG+ 证明了冲突感知策略能显著降低误导采纳，但也暴露出过度拒答问题。RAG 的关键不是读更多文档，而是只基于可信证据作答。

References

- [1] Asai et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. 2023.
- [2] Yan et al. Corrective Retrieval Augmented Generation. 2024.
- [3] Yan et al. EGI-Automated Evaluation of Retrieval RAG+.

面向噪声文档的 Evidence-Gated Iterative RAG (EGI-RAG) 方法框架




Figure 2: EGI-RAG 方法框架。当前实验实现轻量工程版：检索/重排、证据级判断、证据抽取、基于证据生成和支持性验证。

- [4] Saad-Falcon et al. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. 2023.